

# Projekt 2: Generatory liczb pseudolosowych o zadanym rozkładzie w jednym wymiarze

Kacper Połuszejko, 412183

## Wstęp

Celem ćwiczenia było skonstruowanie jednowymiarowego generatora liczb pseudolosowych o funkcji gęstości prawdopodobieństwa:

$$f(x) = \frac{4}{5}(1 + x - x^3), \quad x \in [0, 1], \quad (1)$$

oraz dystrybuancie:

$$F(x) = \frac{4}{5}\left(x + \frac{x^2}{2} - \frac{x^4}{4}\right), \quad x \in [0, 1]. \quad (2)$$

Do generowania liczb pseudolosowych wykorzystano schematy dla: a) rozkładu złożonego, b) łańcucha Markowa, c) metody eliminacji.

## 1 Metodyka

### 1.1 Rozkład złożony

Dystrybuantę zapisujemy w postaci rozkładu złożonego o ogólnym wzorze:

$$F(x) = \sum_{i=1}^n g_i H_i(x), \quad g_i \in R, \quad H_i(x) : R \rightarrow R, \quad (3)$$

zatem w naszym przypadku:

$$F(x) = \frac{4}{5}x + \frac{1}{5}(2x^2 - x^4),$$

skąd odczytujemy:

$$g_1 = \frac{4}{5}, \quad H_1 = x,$$

$$g_2 = \frac{1}{5}, \quad H_2 = 2x^2 - x^4.$$

Funkcje odwrotne do  $H_1$  oraz  $H_2$ :

$$x = U, \quad x = \sqrt{1 - \sqrt{1 - U}}, \quad U \sim U(0, 1). \quad (4)$$

W związku z tym, powyższy rozkład złożony wygenerowany został wg. następującego algorytmu:

$$U_1, U_2 \sim U(0, 1)$$

$$X = \begin{cases} U_2, & \text{gdy } U_1 \leq g_1 \\ \frac{U_2}{\sqrt{1-\sqrt{1-U_2}}}, & \text{gdy } U_1 > g_1 \end{cases}$$

## 1.2 Łańcuch Markowa

W metodzie tej generujemy ciąg

$$\{X_0, X_1, X_2, \dots\}$$

gdzie związek pomiędzy ostatnim elementem  $X_i$  a kolejnym  $X_{i+1}$  określamy na podstawie prawdopodobieństwa przejścia, które spełnia warunek **detailed balance**

$$T(X_{i+1}|X_i) = T(X_i|X_{i+1}) = \frac{1}{2\Delta}, \quad \Delta \in [0, 1]$$

i prawdopodobieństwa akceptacji nowego stanu (liczby)

$$p_{acc} = \min \left\{ \frac{T(X_i|X_{i+1})f(X_{i+1})}{T(X_{i+1}|X_i)f(X_i)}, 1 \right\},$$

gdzie  $T(X_i|X_{i+1})/T(X_{i+1}|X_i)$  jest równe 1 dzięki spełnieniu warunku detailed balance.

Algorytm Metropolis'a generowania nowego elementu w łańcuchu:

$$U_1, U_2 \sim U(0, 1)$$

$$X_{i+1} = \begin{cases} x_{new} = X_i + (2U_1 - 1)\Delta, & \text{gdy } x_{new} \in [0, 1] \wedge U_2 \leq p_{acc} \\ X_i, & \text{w przeciwnym przypadku} \end{cases}$$

## 1.3 Metoda eliminacji

W tej metodzie wykorzystywana jest funkcja gęstości prawdopodobieństwa  $f(x)$ , dodatkowo ograniczona od góry funkcją  $g(x)$ , dla której dysponujemy generatorem **G**. Algorytm generowania ciągu liczb pseudolosowych przedstawia się w następujący sposób:

$$U_1 \sim U(0, 1)$$

$$G_2 \sim \mathcal{G}, \quad \text{np. } \mathcal{G} = 1.15 \cdot U(0, 1)$$

$$\begin{cases} G_2 \leq f(U_1) \implies X = U_1 \\ G_2 > f(U_1) \implies \text{losujemy nową parę } U_1, G_2 \end{cases}$$

## 1.4 Test $\chi^2$

Dla każdej metody wykonano test  $\chi^2$  i porównano uzyskane wyniki z wartością graniczną rozkładu, przyjmując poziom istotności równy  $\alpha = 0.05$ . Wartość statystyki testowej dla  $k - 1$  stopni swobody obliczono ze wzoru:

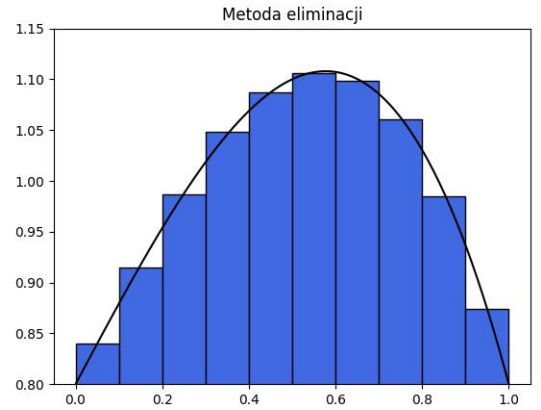

$$\sum_{i=1}^k \frac{(n_i - p_i N)^2}{p_i N}, \quad (5)$$

gdzie  $p_i$  to prawdopodobieństwo, że zmienna losowa znajdzie się w  $i$ -tym przedziale,  $n_i$  to ilość liczb pseudolosowych w  $i$ -tym przedziale, a  $N$  to całkowita liczba wylosowanych liczb.



Na podstawie porównania dla każdej metody stwierdzono, czy hipotezę  $H_0$  tego, że uzyskany ciąg liczb pseudolosowych ma rozkład  $F(x)$  należy odrzucić, czy nie.

## 2 Wyniki

Wygenerowano  $N = 10^6$  liczb pseudolosowych o dystrybucji  $F(x)$  dla każdej z metod. Dla każdego ciągu liczb sporządzono histogram o  $k = 10$  podprzedziałów i porównano go z funkcją  $f(x)$ . Następnie wykonano testy  $\chi^2$ .



**Rys. 1:** Histogramy o liczbie podprzedziałów  $k = 10$  dla ciągów liczb pseudolosowych wygenerowanych za pomocą rozkładu złożonego (po lewej) oraz metody eliminacji (po prawej).



**Rys. 2:** Histogramy o liczbie podprzedziałów  $k = 10$  dla ciągów liczb pseudolosowych wygenerowanych za pomocą łańcucha Markowa z parametrem  $\Delta = 0.5$  (po lewej) oraz  $\Delta = 0.05$  (po prawej).

Dla każdego z wygenerowanych ciągów obliczono wartość statystyki testowej  $\chi^2$  zgodnie ze wzorem (5).

Sprawdzimy teraz, czy hipotezę  $H_0$  tego, że uzyskany ciąg liczb pseudolosowych ma rozkład  $f(x)$  należy odrzucić, czy nie.

**Rozkład złożony:**

$3,325(\alpha = 0,05) < \chi^2_{k-1} = 12,52 < 19,023(\alpha = 0.95)$  - nie odrzucamy hipotezy  $H_0$ .

**Metoda eliminacji:**

$\chi^2_{k-1} = 2,949 < 3,325(\alpha = 0,05)$  - odrzucamy hipotezę  $H_0$ . Generowany rozkład jest zbyt bliski rozkładowi zadanemu.

**Łańcuch Markowa ( $\Delta = 0.5$ ):**

$19,023(\alpha = 0.95) < \chi^2_{k-1} = 23,306$  - odrzucamy hipotezę  $H_0$ . Generowany rozkład za bardzo odbiega od rozkładu zadanego.

**Łańcuch Markowa ( $\Delta = 0.05$ ):**

$19,023(\alpha = 0.95) < \chi^2_{k-1} = 1188,33$  - odrzucamy hipotezę  $H_0$ . Generowany rozkład za bardzo odbiega od rozkładu zadanego.

Widzimy zatem, że jedyną metodą, która przeszła test, jest metoda rozkładu złożonego. Metoda eliminacji okazała się zbyt dokładna. Z kolei ciągi liczb wygenerowane za pomocą łańcucha Markowa za bardzo odbiegały od zadanego rozkładu  $f(x)$ . Warto jednak zwrócić uwagę, że generator ten znacznie lepiej poradził sobie dla parametru  $\Delta = 0.5$  niż  $\Delta = 0.05$  co widać również na (**Rys.2**). Być może przy odpowiednim doborze parametru  $\Delta$  ciąg wygenerowany za pomocą metody łańcucha Markowa przeszedłby test  $\chi^2$ .